

석사학위 논문 설계서

논문 정보

- **대학교:** 건국대학교 정보통신대학원 융합정보기술학과 인공지능전공
 - **제출 목표:** 2026년 9월
 - **실험 환경:**
 - **로컬:** RTX 5060 Ti (16GB VRAM), Ryzen 5 5600X, RAM 32GB — 16GB 재현성 검증용
 - **클라우드:** RunPod RTX 4090 (24GB VRAM) — 주 실험 환경
-

1. 제목

한국어: 경량 멀티모달 모델의 의료 영상 VQA 도메인 적응: QLoRA 파인튜닝과 자율 하이퍼파라미터 최적화

영문: Domain Adaptation of Lightweight Vision-Language Models for Medical Visual Question Answering: QLoRA Fine-Tuning with Autonomous Hyperparameter Optimization

2. 연구 배경 및 목적

2.1 연구 배경

- Vision-Language Model(VLM)의 급속한 발전 (GPT-4V, Gemini 등)
- 의료 영상 분석에서 VLM 활용 가능성 증대
- 범용 VLM의 도메인 특화 성능 한계 (의학 용어, 전문 지식 부족)
- 대규모 GPU 없이도 QLoRA를 통한 효율적 파인튜닝 가능
- 하이퍼파라미터 선택의 자동화는 VLM PEFT의 미해결 과제 (NeurIPS 2024 서베이)

2.2 연구 목적

1. 소비자 GPU(16-24GB) 환경에서 경량 VLM의 의료 VQA 도메인 적응 가능성 실증
2. QLoRA 파인튜닝의 하이퍼파라미터가 성능에 미치는 영향 체계적 분석

3. autoresearch 스타일 자율 실험 루프를 통한 하이퍼파라미터 최적화 방법론 제안

3. 연구 질문

#	연구 질문	귀무가설
RQ1	경량 VLM(2-3B)의 의료 VQA 제로샷 성능은 모델별로 유의미한 차이가 있는가?	H0: 모델 간 VQA 정확도 차이 없음
RQ2	QLoRA 파인튜닝이 의료 VQA 성능을 유의미하게 향상시키는가?	H0: Base = Fine-tuned 성능
RQ3	LLM 에이전트 기반 자율 하이퍼파라미터 탐색이 베이지안 최적화 (Optuna TPE)와 경쟁적 성능을 달성하면서 해석 가능한 탐색 근거를 제공하는가?	H0: Autoresearch = Optuna (TPE)

4. 실험 설계

4.1 대상 모델 (4개)

모델	파라미터	아키텍처 특징	예상 QLoRA VRAM
Qwen3-VL-2B	2B	Thinking mode, DeepStack	~8-10 GB
Qwen2.5-VL-3B	3B	Dynamic Resolution, 19개 언어 OCR	~8-10 GB
SmolVLM-2.2B	2.2B	HuggingFace 경량 VLM	~8-10 GB
Gemma4-E2B	2.3B (active) / 5.1B (total)	PLE(Per-Layer Embeddings), Apache 2.0	~12-14 GB

선택 기준: - 16GB VRAM에서 QLoRA 파인튜닝 가능 - Apache 2.0 또는 MIT 라이선스 (연구 활용 자유) - 충분한 커뮤니티/프레임워크 지원

4.2 데이터셋 (3개)

데이터셋	이미지 수	QA 쌍	언어	도메인	질문 유형
PathVQA	4,998	32,799	영어	병리학	Open+Closed (7종)
SLAKE	642	14,028	영어+중국어	방사선/CT	Open+Closed
VQA-RAD	315	2,248	영어	방사선	Open+Closed

데이터 분할: 각 데이터셋의 공식 train/val/test split 사용

4.2.1 데이터 오염 통제 절차

PathVQA(2018), SLAKE(2021), VQA-RAD(2018)는 본 연구의 대상 모델(Qwen3-VL 2025, Qwen2.5-VL 2025, SmolVLM2 2025, Gemma4 2026) 사전훈련 시점 이전에 공개되었으므로, **사전훈련 데이터 오염 가능성을 배제할 수 없다**. 본 연구는 이를 능동적으로 측정한다.

Min-K% Probability Attack (Shi et al., NAACL 2024):

각 sample의 정답 텍스트에 대해 모델의 token-level log-probability를 계산하고, 하위 K%(K=20) token의 평균 log-probability를 contamination indicator로 사용한다.

수식: $\text{MinK_score}(x) = \text{mean}(\{\log P(x_i | x_{<i}) : x_i \text{ in bottom-K\% by log-prob}\})$

이론: 사전훈련 데이터에 포함된 sample은 비훈련 sample 대비 평균적으로 높은 token 확률을 보임 → MinK_score가 높음.

실험 절차: 1. 4개 모델 × 3개 데이터셋의 모든 test sample에 MinK_score 계산 2. Calibration set(공개 데이터셋 무작위 샘플 1,000개, 본 데이터셋과 유사한 도메인)으로 threshold T 결정 3. MinK_score > T인 sample을 "contamination 의심" 분류 4. Sub-analysis: 의심 sample 제거 후 Phase 1/2 결과 재계산

해석 시나리오: - Clean subset vs 전체 결과 차이 < 1%p: 본 연구 결론 robust - 차이 1-5%p: 한계점에 명시, clean subset 기준 결과를 보조 보고 - 차이 > 5%p: 결론 재검토, 의심 sample 제거 결과를 primary로 보고

구현: `scripts/measure_contamination.py` (별도 모듈, Phase 1 결과 산출 후 실행)

4.3 Phase 1: 베이스라인 평가 (RQ1)

목적: 파인튜닝 전 각 모델의 의료 VQA 제로샷 성능 측정

실험 조건: - 4개 모델 × 3개 데이터셋 = 12개 조건 - 각 조건 3회 반복 (프롬프트 순서 shuffle, seed: 42, 123, 456) - 동일 프롬프트 템플릿 사용

측정 지표: - Closed-ended accuracy (Yes/No, 선택형) - Open-ended accuracy (정답 토큰 매칭) - 응답 시간 (ms/question) - VRAM 사용량 (peak MB)

통계 검증: - ANOVA (4개 모델 간 성능 차이) - 사후 검증: Tukey HSD - 유의수준: alpha = 0.05

4.4 Phase 2: QLoRA 파인튜닝 (RQ2)

목적: 도메인 특화 파인튜닝의 효과 측정

기본 QLoRA 설정:

파라미터	값
Quantization	NF4 (4-bit NormalFloat)
LoRA Rank	16
LoRA Alpha	32
LoRA Dropout	0.05
Target Modules	q_proj, v_proj
Learning Rate	2e-4
Batch Size	1 (gradient accumulation 8)
Epochs	3
Optimizer	paged_adamw_8bit

실험 조건: - 4개 모델 x 3개 데이터셋 = 12개 조건 - 각 조건 3회 반복 (seed 변경: 42, 123, 456)

Ablation Study A - 데이터 크기 영향: - PathVQA 기준, 최적 모델 1개 선택 - 훈련 데이터 비율: 5%, 10%, 25%, 50%, 100% - 학습 곡선(learning curve) 분석

Ablation Study B - LoRA Rank 영향: - PathVQA 기준, 최적 모델 1개 선택 - LoRA rank: 4, 8, 16, 32, 64 - 성능 vs 파라미터 효율성 분석

Ablation Study C - Target Module 영향: - [q_proj, v_proj] vs [q_proj, k_proj, v_proj, o_proj] vs [all_linear] - 성능 vs 학습 시간 트레이드오프

측정 지표 (Phase 1과 동일 + 추가): - Open-ended accuracy: Exact Match + BERTScore F1 이중 보고 - 범용 기준: roberta-large (threshold ≥ 0.7) — 선행 연구 비교용 - 의료 특화 기준: BioBERT (dmis-lab/biobert-v1.1) — 의료 용어 민감도 향상 - 두 지표 간 상관관계 분석 보고 - 훈련 시간 (총 분) - 훈련 가능 파라미터 비율 (%) - Peak VRAM 사용량 (MB) - Catastrophic Forgetting 측정 (아래 상세)

Catastrophic Forgetting 측정 방법:

(A) 범용 VQA 성능 변화: - 대조군: VQAv2 validation subset (2,000 샘플, 균형 샘플링) - 측정 시점: 파인튜닝 전(Base) 1회 + 파인튜닝 후(QLoRA) 1회 - 지표: 범용 VQA 정확도 감소율 = $(\text{Base} - \text{Fine-tuned}) / \text{Base} \times 100\%$ - 적용 범위: 12개 조건(4모델 x 3데이터셋) 각각에 대해 측정

(B) 의료 도메인 내 cross-dataset 일반화: - 훈련 데이터셋 $\neq$ 평가 데이터셋 조합으로 일반화 능력 측정 - 예: PathVQA로 훈련 $\rightarrow$ SLAKE, VQA-RAD로 평가 (각 조합 측정) - 지표: cross-dataset 정확도 변화율 - 적용 범위: 12개 조건 x 2개 cross-dataset = 24회 추가 평가

통계 검증:

$n=9$ (3 seeds $\times$ 3 datasets)의 한계를 인지하므로, 3가지 방법을 병행하여 robustness를 검증한다:

- **Primary:** Paired t-test + Cohen's d (관행 비교)
- **Robust:** BCa Bootstrap (10,000 resamples) $\rightarrow$ 95% CI for Cohen's d
- **Random effects:** Mixed-Effects Model
- 모델: `accuracy ~ condition + (1|seed) + (1|dataset)`
- Library: statsmodels.formula.api.mixedlm 또는 R lme4
- Fixed effect의 t-value, p-value, ICC 보고
- **Non-parametric:** Wilcoxon signed-rank test + 효과 크기 r ($z / \sqrt{n}$)

해석 가이드: t-test와 mixed-effects의 결과가 일치하면 robust한 결론. 불일치 시 BCa CI를 기준으로 판단.

4.4.5 임상적 의미 분석

단순 accuracy로는 의료 AI의 가치를 포착할 수 없다. 본 연구는 두 가지 보조 지표를 추가 보고한다.

(1) Weighted Clinical Accuracy (WCA)

PathVQA는 7개 질문 유형(Where, What, Why, How, How much/many, When, Yes/no) 라벨을 제공한다. 임상 중요도에 따라 가중치를 부여하여 WCA를 산출한다:

유형	임상 중요도	가중치	근거
Diagnosis (Why, What is wrong)	High	1.0	진단 오류는 치료 방향 결정에 직접 영향
Location (Where)	Medium-High	0.8	병변 위치 식별은 후속 검사 결정
Measurement (How much/many)	Medium	0.7	정량 측정은 보조적이나 중요
Description (What, How)	Medium	0.6	소견 기술은 상세 정보 제공
Temporal (When)	Low-Medium	0.5	시간 정보는 부수적
Yes/No	Baseline	0.5	이진 판단의 정보량 제한

수식: $WCA = \sum (\text{유형별 정확도} \times \text{가중치}) / \sum \text{가중치}$

(2) Expected Calibration Error (ECE)

의료 AI에서는 "모델의 자신감이 실제 정확도와 일치하는지"가 accuracy보다 중요한 경우가 많다 (Guo et al., ICML 2017).

수식: $ECE = \sum (|B_m|/n) \times |acc(B_m) - conf(B_m)|$

- $M = 10$ bins (confidence 0.0-0.1, 0.1-0.2, ..., 0.9-1.0)
- B_m : bin m 에 속하는 sample 집합
- 낮을수록 calibration이 좋음 (이상적 값: 0)

임상적 유의미성 임계점: - 선행 연구 인용: FDA AI/ML SaMD guidance (2021), Topol (Nature Medicine 2019), Liu et al. (Lancet Digital Health 2019) - 단순 비교: 5%p accuracy 향상 → 1,000명 진단 시 50명 추가 정확 분류 - WCA 기준: high-criticality 유형에서의 향상이 핵심 기여 - ECE 기준: 0.05 이하 권장 (well-calibrated)

4.5 Phase 3: 자율 하이퍼파라미터 최적화 (RQ3)

목적: autoresearch 패턴 기반 자율 HPO의 효과 검증 — Optuna(TPE) 대비 경쟁적 성능 및 해석 가능성 평가

탐색 공간:

파라미터	탐색 범위	타입
lora_rank	{4, 8, 16, 32, 64}	이산
lora_alpha	rank x {1, 2, 4}	이산
learning_rate	[1e-5, 5e-4]	연속 (로그스케일)
batch_size	{1, 2, 4}	이산
grad_accum_steps	{4, 8, 16}	이산
warmup_ratio	[0.0, 0.1]	연속
weight_decay	[0.0, 0.1]	연속
lora_targets	{minimal, medium, full}	범주형
max_steps	{100, 200, 400, 800}	이산

비교 대상 (4가지 HPO 전략):

전략	설명	trial 수
Manual	연구자가 직접 설정한 기본값	1
Random Search	탐색 공간에서 무작위 샘플링	~40
Optuna (TPE)	베이지안 최적화 (Tree-structured Parzen Estimator)	~40
Autoresearch	LLM 에이전트 기반 자율 탐색	~40

자율 탐색 루프 (autoresearch 스타일): 1. 에이전트가 이전 실험 결과(results.tsv) 읽기 2. 다음 실험 설정 제안 + 자연어로 변경 근거 기록 (config.yaml + rationale.md) 3. Git commit 4. 고정 max_steps 학습 실행 5. 검증 세트 평가 -> VQA accuracy 기록 6. 성능 향상 시 keep, 그렇지 않으면 discard 7. 반복 (40회 또는 하룻밤)

고정 조건: - 동일 모델 (Phase 2에서 최적 모델 1개) - 동일 데이터셋 (PathVQA) - 고정 학습량: max_steps 고정 (200 steps) — trial 간 동일 학습 step 수 보장 - 동일 검증 세트

예상 실험 규모: - 총 trial 수: Manual 10회 + RS 400회(40x10) + Optuna 400회(40x10) + AutoResearch 400회(40x10) = 1,210회 - trial당 소요: ~10분 (max_steps=200 학습 + 검증 평가, RTX 4090 기준) - 예상 총 GPU 시간: ~200 GPU-hours (RunPod RTX 4090 기준 약 8-9일, 24h 가동)

측정 지표: - 최종 최적 VQA accuracy - 최적 도달까지 실험 횟수 - 총 소요 시간 (wall-clock) - 탐색 효율성 (최적 성능 / 총 실험 수) - 탐색 궤적 시각화 (실험 번호 vs accuracy 그래프) - effective_batch_size, total_samples_seen 보고 - AutoResearch: 각 trial별 자연어 탐색 근거 로그

통계 검증 (Run-level 분석):

본 연구는 "trial-level"이 아닌 "**run-level**"에서만 비교 통계 검정을 수행한다. AutoResearch와 Optuna는 sequential optimization 특성상 동일 run 내 trial 간 의존성이 존재하므로(trial t의 결과가 trial t+1의 제안에 영향), 40개 trial을 독립 관측치로 간주하는 것은 통계적 가정 위반이다.

분석 단위: - **Run-level (검정 단위):** 각 전략 × 10회 독립 반복 → 10개 final best accuracy 값 (서로 다른 seed, 서로 다른 시작 config) - **Trial-level (시각화 전용):** 학습 궤적, anytime performance curve, 탐색 효율성 시각화

적용 검정: - Kruskal-Wallis test: 4그룹 × n=10 (자유도 3, 검정력 ~0.7) - Mann-Whitney U test: AutoResearch vs Optuna 쌍별 비교 (n=10 vs n=10) - BCa Bootstrap 95% CI: 각 전략의 최종 성능 분포 - Anytime Performance Curve (보조): X축 trial 번호, Y축 best-so-far accuracy, 평균 + 95% bootstrap CI 밴드

5. 논문 구조 (장별 구성)

제1장. 서론 (약 5p)

- 1.1 연구 배경
- 1.2 연구 목적
- 1.3 연구 범위 및 제한
- 1.4 논문 구성

제2장. 이론적 배경 (약 15p)

- 2.1 Vision-Language Model 개요
 - 2.1.1 멀티모달 학습의 발전
 - 2.1.2 경량 VLM 아키텍처 (Qwen-VL, SmolVLM 등)
- 2.2 Parameter-Efficient Fine-Tuning
 - 2.2.1 LoRA (Low-Rank Adaptation)
 - 2.2.2 QLoRA (Quantized LoRA)
 - 2.2.3 기타 PEFT 기법 비교

- 2.3 의료 영상 Visual Question Answering
 - 2.3.1 Medical VQA 과제 정의
 - 2.3.2 주요 벤치마크 데이터셋
 - 2.3.3 기존 연구 성과 (LLaVA-Med, Med-Flamingo, CheXagent 등 의료 특화 VLM 포함)
- 2.4 자율 하이퍼파라미터 최적화
 - 2.4.1 전통적 HPO (Grid, Random, Bayesian)
 - 2.4.2 LLM 에이전트 기반 최적화 (autoresearch)
 - 베이지안 최적화 대비 LLM HPO의 이론적 차별점: cross-domain transfer, 탐색 공간 구조 이해, 자연어 기반 설명 가능성
 - 조기 학습 신호 기반 HPO의 이론적 정당성: Hyperband(Li et al., 2018)의 successive halving, 초반 학습 곡선과 최종 수렴 성능 간 순위 상관관계 (Phase 2 Ablation A 학습 곡선 결과로 본 연구 내 자체 실증)
- 2.5 선행 연구 요약 및 본 연구의 차별점

제3장. 연구 방법 (약 15p)

- 3.1 연구 설계 개요
- 3.2 실험 환경 및 도구
 - 3.2.1 하드웨어 사양 (로컬 RTX 5060 Ti + 클라우드 RTX 4090 이원 구성)
 - 3.2.2 소프트웨어 스택 (HuggingFace, Optuna 등)
- 3.3 대상 모델 및 선정 기준
- 3.4 데이터셋 및 전처리
- 3.5 실험 1: 제로샷 베이스라인 평가
- 3.6 실험 2: QLoRA 파인튜닝
- 3.7 실험 3: 자율 하이퍼파라미터 최적화
- 3.8 평가 지표 및 통계 분석 방법
 - 3.8.1 BERTScore 이중 보고 (roberta-large + BioBERT)
 - 3.8.2 Catastrophic Forgetting 이중 측정 (VQAv2 + cross-dataset)
 - 3.8.3 임상적 의미 분석 (WCA + ECE)
 - 3.8.4 Robust 통계 (Bootstrap + Mixed-Effects)
 - 3.8.5 데이터 오염 통제 (Min-K% Probability)

제4장. 실험 결과 및 분석 (약 20p)

- 4.1 Phase 1: 제로샷 베이스라인 결과
 - 4.1.1 모델별 성능 비교
 - 4.1.2 데이터셋별 난이도 분석
 - 4.1.3 오류 유형 분석

- 4.2 Phase 2: QLoRA 파인튜닝 결과
 - 4.2.1 Base vs Fine-tuned 성능 향상
 - 4.2.2 데이터 크기 영향 (Ablation A)
 - 4.2.3 LoRA Rank 영향 (Ablation B)
 - 4.2.4 Target Module 영향 (Ablation C)
 - 4.2.5 Catastrophic Forgetting 분석 (VQAv2 + cross-dataset)
- 4.3 Phase 3: 자율 HPO 결과
 - 4.3.1 각 전략의 최적 성능 비교 (Autoresearch vs Optuna 중심)
 - 4.3.2 탐색 효율성 비교
 - 4.3.3 탐색 궤적 분석
 - 4.3.4 발견된 최적 하이퍼파라미터 조합
 - 4.3.5 Autoresearch 탐색 근거 해석 가능성 분석
- 4.4 종합 분석 및 논의

제5장. 결론 (약 5p)

- 5.1 연구 요약
- 5.2 연구 기여
- 5.3 한계점
- **데이터 오염 능동적 통제의 한계:** Min-K% Probability(Shi et al., NAACL 2024)로 contamination 정도를 정량화하나, 이는 간접 indicator이며 완전한 통제는 불가. Clean subset 결과를 보조 보고 하여 결론의 robustness 검증.
- **의료 특화 VLM 직접 비교 부재:** LLaVA-Med, Med-Flamingo 등과 동일 환경에서의 직접 실험 비교는 본 연구 범위 외. 동일 데이터셋·평가 프로토콜의 선행 연구 수치와 간접 비교 (Table 4.4).
- **Phase 3 confounding:** max_steps 고정에도 effective_batch_size에 따른 total_samples_seen 차이 존재. 모든 trial의 effective_batch, samples_seen, wall_clock_time을 투명하게 보고.
- **LLM 비결정성:** Autoresearch의 API 비결정성으로 완전 재현 불가. temperature=0, top_p=1, 모델 ID + 스냅샷 날짜 고정, API 응답 로깅, 10회 반복으로 변동성 흡수.
- **Ablation Study 일반화:** LoRA Rank/Target Module/데이터 크기 Ablation은 PathVQA + 최적 모델 1개 기준 수행. SLAKE rank=8,16,32 보조 검증으로 일관성만 확인. 전체 cross-dataset 확장은 향후 연구.
- **통계적 검정력의 한계:** Phase 2 paired t-test n=9, Phase 3 run-level KW n=10. BCa Bootstrap + Mixed-Effects + Wilcoxon 등 3중 검증으로 robust한 결론 유도하나, n 자체의 한계로 효과 크기 추정 구간은 넓을 수 있음.
- **임상적 의미의 간접 추정:** WCA(Weighted Clinical Accuracy)는 질문 유형별 가중치를 본 연구자가 부여한 임시 척도. 임상 의사 검증을 거친 표준 가중치 체계는 후속 연구 필요.
- 5.4 향후 연구 방향

참고문헌

부록

- A. 상세 실험 결과 표
- B. autoresearch 에이전트 program.md
- C. 실험 재현 가이드
- D. Autoresearch 탐색 근거 로그 (자연어 rationale 전문)

6. 재현성 보장 계획

항목	방법
코드 관리	GitHub 리포지토리 (실험 코드 + 설정 파일)
환경 재현	pyproject.toml + CUDA 버전 명시
실험 추적	Weights & Biases + results.tsv
랜덤 시드	모든 실험에 seed 고정 (42, 123, 456)
반복 실험	각 조건 최소 3회 반복 -> 평균 +/- 표준편차 보고
데이터 버전	데이터셋 버전 및 다운로드 URL 명시
Git 커밋	각 실험 설정을 git commit으로 추적
LLM 비결정성 통제	temperature=0, top_p=1, 모델 ID 및 스냅샷 날짜 고정
API 응답 로깅	전체 API 요청/응답 JSON을 실험별 로그 파일로 저장
변동성 흡수	Phase 3 각 전략 10회 반복으로 분포 보고

7. 예상 결과 테이블 (형식 예시)

Table 4.1: 제로샷 베이스라인 결과 (VQA Accuracy %)

모델	PathVQA (Open)	PathVQA (Closed)	SLAKE (Open)	SLAKE (Closed)	VQA-RAD (Open)	VQA-RAD (Closed)
Qwen3-VL-2B	??? +/- ???	??? +/- ???	...	...	...	...
Qwen2.5-VL-3B	...	...	...	...	...	...
SmolVLM-2.2B	...	...	...	...	...	...
Gemma4-E2B	...	...	...	...	...	...

Table 4.2: QLoRA 파인튜닝 전후 비교

모델	조건	PathVQA (EM)	PathVQA (BERTScore-roberta)	PathVQA (BERTScore-BioBERT)	SLAKE Acc.	VQA-RAD Acc.	향상 율
Qwen3-VL-2B	Zero-shot	...	...	...	...	...	-
Qwen3-VL-2B	QLoRA	...	...	...	...	...	+?.? %
...	...	...	...	...	...	...	...

Table 4.2b: Catastrophic Forgetting 측정

(A) VQAv2 subset (범용 VQA)

모델	학습 데이터셋	Base Acc.	Fine-tuned Acc.	감소율 (%)
Qwen3-VL-2B	PathVQA	???	???	??%
Qwen3-VL-2B	SLAKE	???	???	??%
...	...	...	...	...

(B) 의료 도메인 내 cross-dataset 일반화

모델	훈련	평가	Base Acc.	Fine-tuned Acc.	변화율 (%)
Qwen3-VL-2B	PathVQA	SLAKE	???	???	??%
Qwen3-VL-2B	PathVQA	VQA-RAD	???	???	??%
...	...	...	...	...	...

Table 4.3: HPO 전략 비교 (PathVQA, 최적 모델)

HPO 전략	최적 Accuracy	실험 횟수	총 시간 (h)	효율 성	effective_batch 범 위	total_samples 범 위
Manual (기본 값)	???	1	??	-	8	??K
Random Search	??? +/- ???	40	~??	???	4-64	??K-??K
Optuna (TPE)	??? +/- ???	40	~??	???	4-64	??K-??K
Autoresearch	??? +/- ???	40	~??	???	4-64	??K-??K

Table 4.4: 의료 특화 VLM vs 본 연구 경량 VLM

본 연구의 경량 범용 VLM(2-3B)이 의료 특화 모델 대비 어느 수준에 도달하는지 간접 비교한다. 모델 크기와 학습 데이터가 다르므로 직접 공정 비교는 어려우나, 동일 데이터셋·동일 평가 프로토콜의 선행 연구 수치와 대조하여 실용적 가치를 평가한다.

모델	파라미터	학습 데이터	PathVQA (Open)	PathVQA (Closed)	SLAKE (Open)	VQA-RAD (Open)	출처
LLaVA-Med-7B	7B	PMC-15M + LLaVA-Med Inst.	39.6%	91.2%	38.8%	31.2%	Li et al., NeurIPS 2023
Med-Flamingo	8.3B (active)	MTB + PMC-OA	35.8%	88.0%	-	-	Moor et al., 2023
CheXagent	7B (Mistral-7B 기반)	CheXinstruct + PadChest	-	-	-	45.1% (chest)	Chen et al., 2024
BioViL-T	0.4B	MIMIC-CXR	-	-	-	28.4% (chest)	Bannur et al., CVPR 2023
Qwen3-VL-2B (제로샷, 본 연구)	2B	일반 멀티모달	??%	??%	??%	??%	-
Qwen3-VL-2B (QLoRA, 본 연구)	2B	일반 + 의료 fine-tune	??%	??%	??%	??%	-
Gemma4-E2B (제로샷, 본 연구)	2.3B/5.1B	일반 멀티모달	??%	??%	??%	??%	-
Gemma4-E2B (QLoRA, 본 연구)	2.3B/5.1B	일반 + 의료 fine-tune	??%	??%	??%	??%	-

해석 가이드: - 본 연구 모델은 의료 특화 학습 데이터의 1/100 이하 규모로 학습 시도 - 본 연구의 가치: (1) 의료 특화 모델 대비 어느 정도 격차, (2) 소비자 GPU에서 운용 가능한 경량 솔루션, (3) 도메인 적응 효율성 분석 - 의료 특화 모델 대비 격차가 클 경우: future work에서 "본 연구 방법론 + 의료 특화 데이터"의 결합 가능성 제시 - 격차가 적을 경우: 경량 범용 VLM + QLoRA가 실용적 대안임을 실증