

THESIS_PROPOSAL_FINAL_v0.3

석사학위 논문 설계서

Version: v0.3 (2026-04-05)

변경 이력

버전	날짜	변경 내용
v0.1	2026-03-22	교수 제출용 초안 (3개 모델 기준)
v0.2	2026-03-24	리뷰 피드백 반영: Phase 2 평가 지표 정교화(BERTScore, CF 대조군), Phase 3 탐색 공간 개선(max_steps), 시간 예산 정의 명확화
v0.3	2026-04-05	Gemma 4 E2B 모델 추가 (4개 모델), transformers 5.5.0, 실험 조건 수 업데이트

논문 정보

- 대학교: 건국대학교 정보통신대학원 융합정보기술학과 인공지능전공
- 제출 목표: 2026년 9월
- 실험 환경: RTX 5060 Ti (16GB VRAM), Ryzen 5 5600X, RAM 32GB

1. 제목

한국어: 경량 멀티모달 모델의 의료 영상 VQA 도메인 적응: QLoRA 파인튜닝과 자율 하이퍼파라미터 최적화

영문: Domain Adaptation of Lightweight Vision-Language Models for Medical Visual Question Answering: QLoRA Fine-Tuning with Autonomous Hyperparameter Optimization

2. 연구 배경 및 목적

2.1 연구 배경

- Vision-Language Model(VLM)의 급속한 발전 (GPT-4V, Gemini 등)
- 의료 영상 분석에서 VLM 활용 가능성 증대

- 범용 VLM의 도메인 특화 성능 한계 (의학 용어, 전문 지식 부족)
- 대규모 GPU 없이도 QLoRA를 통한 효율적 파인튜닝 가능
- 하이퍼파라미터 선택의 자동화는 VLM PEFT의 미해결 과제 (NeurIPS 2024 서베이)

2.2 연구 목적

1. 소비자 GPU(16GB) 환경에서 경량 VLM의 의료 VQA 도메인 적응 가능성 실증
2. QLoRA 파인튜닝의 하이퍼파라미터가 성능에 미치는 영향 체계적 분석
3. autoresearch 스타일 자율 실험 루프를 통한 하이퍼파라미터 최적화 방법론 제안

3. 연구 질문

#	연구 질문	귀무가설
RQ1	경량 VLM(2-3B)의 의료 VQA 제로샷 성능은 모델별로 유의미한 차이가 있는가?	H0: 모델 간 VQA 정확도 차이 없음
RQ2	QLoRA 파인튜닝이 의료 VQA 성능을 유의미하게 향상시키는가?	H0: Base = Fine-tuned 성능
RQ3	자율 하이퍼파라미터 탐색이 기존 HPO 방법보다 효율적인가?	H0: 자율 탐색 = Random Search

4. 실험 설계

4.1 대상 모델 (4개)

모델	파라미터	아키텍처 특징	예상 QLoRA VRAM
Qwen3-VL-2B	2B	Thinking mode, DeepStack	~8-10 GB
Qwen2.5-VL-3B	3B	Dynamic Resolution, 19개 언어 OCR	~8-10 GB
SmolVLM-2.2B	2.2B	HuggingFace 경량 VLM	~8-10 GB
Gemma4-E2B	2.3B (active) / 5.1B (total)	PLE(Per-Layer Embeddings), Apache 2.0	~12-14 GB

v0.3 변경: Gemma 4 E2B 추가. PLE 기술로 2.3B active 파라미터만으로 5.1B급 표현력 제공. 제로샷 VRAM ~10.3GB 확인.

선정 기준:

- 16GB VRAM에서 QLoRA 파인튜닝 가능
- Apache 2.0 또는 MIT 라이선스 (연구 활용 자유)
- 충분한 커뮤니티/프레임워크 지원

4.2 데이터셋 (3개)

데이터셋	이미지 수	QA 쌍	언어	도메인	질문 유형
PathVQA	4,998	32,799	영어	병리학	Open+Closed (7종)
SLAKE	642	14,028	영어+중국어	방사선/CT	Open+Closed
VQA-RAD	315	2,248	영어	방사선	Open+Closed

데이터 분할: 각 데이터셋의 공식 train/val/test split 사용

4.3 Phase 1: 베이스라인 평가 (RQ1)

목적: 파인튜닝 전 각 모델의 의료 VQA 제로샷 성능 측정

실험 조건:

- 4개 모델 x 3개 데이터셋 = 12개 조건
- 각 조건 3회 반복 (프롬프트 순서 shuffle, seed: 42, 123, 456)
- 동일 프롬프트 템플릿 사용

측정 지표:

- Closed-ended accuracy (Yes/No, 선택형)
- Open-ended accuracy (정답 토큰 매칭)
- 응답 시간 (ms/question)
- VRAM 사용량 (peak MB)

통계 검증:

- ANOVA (4개 모델 간 성능 차이)
- 사후 검증: Tukey HSD
- 유의수준: alpha = 0.05

4.4 Phase 2: QLoRA 파인튜닝 (RQ2)

목적: 도메인 특화 파인튜닝의 효과 측정

기본 QLoRA 설정:

파라미터	값
Quantization	NF4 (4-bit NormalFloat)
LoRA Rank	16
LoRA Alpha	32
LoRA Dropout	0.05
Target Modules	q_proj, v_proj
Learning Rate	2e-4
Batch Size	1 (gradient accumulation 8)
Epochs	3
Optimizer	paged_adamw_8bit

실험 조건:

- 4개 모델 x 3개 데이터셋 = 12개 조건
- 각 조건 3회 반복 (seed 변경: 42, 123, 456)

Ablation Study A - 데이터 크기 영향:

- PathVQA 기준, 최적 모델 1개 선택
- 훈련 데이터 비율: 5%, 10%, 25%, 50%, 100%
- 학습 곡선(learning curve) 분석

Ablation Study B - LoRA Rank 영향:

- PathVQA 기준, 최적 모델 1개 선택
- LoRA rank: 4, 8, 16, 32, 64
- 성능 vs 파라미터 효율성 분석

Ablation Study C - Target Module 영향:

- [q_proj, v_proj] vs [q_proj, k_proj, v_proj, o_proj] vs [all_linear]
- 성능 vs 학습 시간 트레이드오프

측정 지표 (Phase 1과 동일 + 추가):

- Open-ended accuracy: Exact Match + BERTScore F1 (threshold >= 0.7, roberta-large 기반)

- 훈련 시간 (총 분)
- 훈련 가능 파라미터 비율 (%)
- Peak VRAM 사용량 (MB)
- Catastrophic Forgetting 측정 (아래 상세)

Catastrophic Forgetting 측정 방법:

- 대조군: VQAv2 validation subset (2,000 샘플, 균형 샘플링)
- 측정 시점: 파인튜닝 전(Base) 1회 + 파인튜닝 후(QLoRA) 1회
- 지표: 범용 VQA 정확도 감소율 = (Base - Fine-tuned) / Base x 100%
- 적용 범위: 12개 조건(4모델 x 3데이터셋) 각각에 대해 측정

통계 검증:

- Paired t-test (Base vs Fine-tuned)
- Effect size: Cohen's d
- Wilcoxon signed-rank test (비모수 검증)

4.5 Phase 3: 자율 하이퍼파라미터 최적화 (RQ3)

목적: autoresearch 패턴 기반 자율 HPO의 효과 검증

탐색 공간:

파라미터	탐색 범위	타입
lora_rank	{4, 8, 16, 32, 64}	이산
lora_alpha	rank x {1, 2, 4}	이산
learning_rate	[1e-5, 5e-4]	연속 (로그스케일)
batch_size	{1, 2, 4}	이산
grad_accum_steps	{4, 8, 16}	이산
warmup_ratio	[0.0, 0.1]	연속
weight_decay	[0.0, 0.1]	연속
lora_targets	{minimal, medium, full}	범주형
max_steps	{100, 200, 400, 800}	이산

비교 대상 (4가지 HPO 전략):

전략	설명	하룻밤 실험 수
Manual	연구자가 직접 설정한 기본값	1
Random Search	탐색 공간에서 무작위 샘플링	~40
Optuna (TPE)	베이지안 최적화 (Tree-structured Parzen Estimator)	~40
Autoresearch	LLM 에이전트 기반 자율 탐색	~40

자율 탐색 루프 (autoresearch 스타일):

1. 에이전트가 이전 실험 결과(results.tsv) 읽기
2. 다음 실험 설정 제안 (config.yaml 수정)
3. Git commit
4. 15분 고정 시간 학습 실행 (순수 GPU 학습 시간)
5. 검증 세트 평가 -> VQA accuracy 기록
6. 성능 향상 시 keep, 그렇지 않으면 discard
7. 반복 (40회 또는 하룻밤)

고정 조건:

- 동일 모델 (Phase 2에서 최적 모델 1개)
- 동일 데이터셋 (PathVQA)
- 고정 시간 예산: 15분/실험 (순수 GPU 학습 시간, 모델 로드/평가 시간 제외)
- 동일 검증 세트

측정 지표:

- 최종 최적 VQA accuracy
- 최적 도달까지 실험 횟수
- 총 소요 시간 (wall-clock)
- 탐색 효율성 (최적 성능 / 총 실험 수)
- 탐색 궤적 시각화 (실험 번호 vs accuracy 그래프)

통계 검증:

- Kruskal-Wallis test (4개 전략 간 최종 성능)
 - 각 전략 5회 독립 반복 -> 분포 비교
 - Bootstrap confidence interval
-

5. 논문 구조 (장별 구성)

제1장. 서론 (약 5p)

- 1.1 연구 배경
- 1.2 연구 목적
- 1.3 연구 범위 및 제한
- 1.4 논문 구성

제2장. 이론적 배경 (약 15p)

- 2.1 Vision-Language Model 개요
 - 2.1.1 멀티모달 학습의 발전
 - 2.1.2 경량 VLM 아키텍처 (Qwen-VL, SmolVLM 등)
- 2.2 Parameter-Efficient Fine-Tuning
 - 2.2.1 LoRA (Low-Rank Adaptation)
 - 2.2.2 QLoRA (Quantized LoRA)
 - 2.2.3 기타 PEFT 기법 비교
- 2.3 의료 영상 Visual Question Answering
 - 2.3.1 Medical VQA 과제 정의
 - 2.3.2 주요 벤치마크 데이터셋
 - 2.3.3 기존 연구 성과
- 2.4 자율 하이퍼파라미터 최적화
 - 2.4.1 전통적 HPO (Grid, Random, Bayesian)
 - 2.4.2 LLM 에이전트 기반 최적화 (autoresearch)
- 2.5 선행 연구 요약 및 본 연구의 차별점

제3장. 연구 방법 (약 15p)

- 3.1 연구 설계 개요
- 3.2 실험 환경 및 도구
 - 3.2.1 하드웨어 사양
 - 3.2.2 소프트웨어 스택 (HuggingFace, Optuna 등)
- 3.3 대상 모델 및 선정 기준
- 3.4 데이터셋 및 전처리
- 3.5 실험 1: 제로샷 베이스라인 평가
- 3.6 실험 2: QLoRA 파인튜닝
- 3.7 실험 3: 자율 하이퍼파라미터 최적화
- 3.8 평가 지표 및 통계 분석 방법

제4장. 실험 결과 및 분석 (약 20p)

- 4.1 Phase 1: 제로샷 베이스라인 결과
 - 4.1.1 모델별 성능 비교
 - 4.1.2 데이터셋별 난이도 분석
 - 4.1.3 오류 유형 분석
- 4.2 Phase 2: QLoRA 파인튜닝 결과
 - 4.2.1 Base vs Fine-tuned 성능 향상
 - 4.2.2 데이터 크기 영향 (Ablation A)
 - 4.2.3 LoRA Rank 영향 (Ablation B)
 - 4.2.4 Target Module 영향 (Ablation C)
 - 4.2.5 Catastrophic Forgetting 분석
- 4.3 Phase 3: 자율 HPO 결과
 - 4.3.1 각 전략의 최적 성능 비교
 - 4.3.2 탐색 효율성 비교
 - 4.3.3 탐색 궤적 분석
 - 4.3.4 발견된 최적 하이퍼파라미터 조합
- 4.4 종합 분석 및 논의

제5장. 결론 (약 5p)

- 5.1 연구 요약
- 5.2 연구 기여
- 5.3 한계점
- 5.4 향후 연구 방향

참고문헌

부록

- A. 상세 실험 결과 표
- B. autoresearch 에이전트 program.md
- C. 실험 재현 가이드

6. 재현성 보장 계획

항목	방법
코드 관리	GitHub 리포지토리 (실험 코드 + 설정 파일)
환경 재현	pyproject.toml + CUDA 버전 명시
실험 추적	Weights & Biases + results.tsv
랜덤 시드	모든 실험에 seed 고정 (42, 123, 456)
반복 실험	각 조건 최소 3회 반복 -> 평균 +/- 표준편차 보고
데이터 버전	데이터셋 버전 및 다운로드 URL 명시
Git 커밋	각 실험 설정을 git commit으로 추적

7. 예상 결과 테이블 (형식 예시)

Table 4.1: 제로샷 베이스라인 결과 (VQA Accuracy %)

모델	PathVQA (Open)	PathVQA (Closed)	SLAKE (Open)	SLAKE (Closed)	VQA- RAD (Open)	VQA-RAD (Closed)
Qwen3-VL-2B	?.?? +/- ?.??	?.?? +/- ?.??	...	...	...	...
Qwen2.5-VL-3B	...	...	...	...	...	...
SmolVLM-2.2B	...	...	...	...	...	...

Table 4.2: QLoRA 파인튜닝 전후 비교

모델	조건	PathVQA Acc. (EM)	PathVQA Acc. (BERTScore)	SLAKE Acc.	VQA- RAD Acc.	향상 율
Qwen3-VL-2B	Zero-shot	...	...	...	...	-
Qwen3-VL-2B	QLoRA	...	...	...	...	+?.? %
...	...	...	...	...	...	...

Table 4.2b: Catastrophic Forgetting 측정 (VQAv2 subset)

모델	학습 데이터셋	Base Acc.	Fine-tuned Acc.	감소율 (%)
Qwen3-VL-2B	PathVQA	?.??	?.??	?.??%
Qwen3-VL-2B	SLAKE	?.??	?.??	?.??%
...	...	...	...	...

Table 4.3: HPO 전략 비교 (PathVQA, 최적 모델)

HPO 전략	최적 Accuracy	실험 횟수	총 시간(h)	효율성
Manual (기본값)	?.??	1	0.25	-
Random Search	?.?? +/- ?.??	40	~10	?.??
Optuna (TPE)	?.?? +/- ?.??	40	~10	?.??
Autoresearch	?.?? +/- ?.??	40	~10	?.??